Критерий Колмогорова – Смирнова

Для проверки гипотезы о согласии последовательности величин U_1, U_2, ... с равномерным распределением в промежутке $(0, 1)$ можно пользоваться критерием Колмогорова – Смирнова, основанного на статистике

$$D_n = \max_{1 \leqslant j \leqslant n} \left| \frac{j}{n} - U_{(j)} \right|, \quad \text{где } U_{(1)} \leqslant U_{(2)} \leqslant \ldots \leqslant U_{(n)}$$

есть вариационный ряд, построенный по первым n величинам U_1, U_2, ..., U_n. При больших n в случае выборки и равномерного распределения имеем:

$$\lim_{n \to \infty} \mathbf{P}(\sqrt{n} \cdot D_n < x) = \sum_{k=-\infty}^{\infty} (-1)^k e^{-2k^2 x^2}, \qquad x > 0$$

В среде R можно воспользоваться функцией

`ks.test(u, punif).`

© А.В. Зорин, ННГУ, 2021

Критерий χ^2 Пирсона I

Данный критерий можно применять как для проверки равномерности распределения непрерывных случайных величин U_n, $n = 1, 2, \ldots$, так и для дискретного равномерного распределения величин X_n, $n = 1, 2, \ldots$. (Напомним, что $U_n = X_n/m$.)

Например, возьмем разбиение интервала $[0, 1)$ на равные подынтервалы $[\frac{k-1}{r}, \frac{k}{r})$, $k = 1, 2, \ldots, r$. Теоретические вероятности при равномерном распределении будут r^{-1}. Введем частоты

$$\nu_k = \frac{1}{n} \sum_{i=1}^{n} I\left(\frac{k-1}{r} \leqslant U_i < \frac{k}{r}\right),$$

© А.В. Зорин, ННГУ, 2021

Критерий χ^2 Пирсона II

тогда величина $\sum_{k=1}^{r} \frac{\left(\nu_k - n/r\right)^2}{n/r}$ должна иметь χ^2-распределение с $r-1$ степенью свободы.

Можно применять этот критерий также для проверки гипотез о равномерном распределении в m-мерных единичных кубах, разделяя его на r^m малейших кубов C_l, $l = 1, 2, \ldots, r^m$. Вопрос в том, как считать частоты.
1) Можно использовать группы по m наблюдений подряд:

$$\nu_l = \frac{m}{n} \sum_{i=0}^{n/m-1} I\left(\left(U_{mi+1}, U_{mi+2}, \ldots, U_{mi+(m-1)}\right) \in C_l\right)$$

Тогда индикаторы при справедливой нулевой гипотезе будут независимыми величинами.

© А.В. Зорин, ННГУ, 2021

Критерий χ^2 Пирсона III

2) Можно использовать перекрывающиеся группы:

$$\nu_l = \frac{1}{n-m+1} \sum_{i=1}^{n-m+1} I((U_i, U_{i+1}, \ldots, U_{i+m-1}) \in C_l).$$

В этом случае индикаторы будут зависимыми величинами и это должно изменить распределение статистики критерия при нулевой гипотезе.
Marsaglia: если пары (U_1, U_2), (U_2, U_3), $\ldots$, (U_{n-1}, U_n) классифицировать по d^2 ячейкам квадрата $[0,1) \times [0,1)$ и затем сосчитать статистику хи-квадрат Пирсона, то при справедливой нулевой гипотезе она будет асимптотически распределена как $\chi^2_{d(d-1)}$.

© А.В. Зорин, ННГУ, 2021

Сериальные корреляции / автокорреляционная функция I

Для стационарной случайной последовательности $\boldsymbol{X}_1$, $\boldsymbol{X}_2$, ... мерой зависимости может выступать автокорреляционная функция

$$\rho(k) = corr(\boldsymbol{X}_n, \boldsymbol{X}_{n+k}) = \frac{\mathrm{cov}(\boldsymbol{X}_n, \boldsymbol{X}_{n+k})}{\sqrt{\mathrm{D}\boldsymbol{X}_n \mathrm{D}\boldsymbol{X}_{n+k}}}.$$

Оценка по выборке x_1, x_2, ..., x_n может быть проведена несколькими способами:

$$\hat{\rho}(k) = \frac{\frac{1}{n-k}\sum_{i=1}^{n-k} x_i x_{i+k} - \left(\frac{1}{n}\sum_{i=1}^{n} x_i\right)^2}{\frac{1}{n}\sum_{i=1}^{n} x_i^2 - \left(\frac{1}{n}\sum_{i=1}^{n} x_i\right)^2},$$

© А.В. Зорин, ННГУ, 2021

Сериальные корреляции / автокорреляционная функция II

$$\hat{\rho}(k) = \frac{\frac{1}{n}(x_1 x_{k+1} + x_2 x_{k+2} + \ldots + x_{n-1} x_{k-1} + x_n x_k) - \left(\frac{1}{n}\sum_{i=1}^{n} x_i\right)^2}{\frac{1}{n}\sum_{i=1}^{n} x_i^2 - \left(\frac{1}{n}\sum_{i=1}^{n} x_i\right)^2}$$

Для последовательности некоррелированных величин выборочные автокорреляции должны быть близки к нулю.
В `R` есть полезная функция `acf(x)`.

© А.В. Зорин, ННГУ, 2021

Другие эмпирические критерии I

Имеется более дюжины специфических критериев, которые применяются для проверки «случайноподобия» последовательности.
Существуют библиотеки тестов: `Diehard` (Marsaglia, 1995; `http://webhome.phy.duke.edu/~rgb/General/dieharder.php`), библиотека `CryptRndTest` для `R`.
По-видимому, такие тесты придумывают, чтобы «провалить» конкретный генератор. Рассмотрим пример теста «дней рождения».

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения I

Пусть дана повторная выборка

$$(x_1, x_2, \ldots, x_n)$$

элементов множества $\{0, 1, \ldots, m-1\}$. Построим по ней вариационынй ряд

$$x_{(1)} \leqslant x_{(2)} \leqslant \ldots \leqslant x_{(n)}$$

и сосчитаем *промежутки*

$$S_1 = x_{(2)} - x_{(1)}, \quad S_2 = x_{(3)} - x_{(2)}, \quad \ldots$$
$$\ldots, \quad S_{n-1} = x_{(n)} - x_{(n-1)}, \quad S_n = x_{(1)} + m - x_{(n)}.$$

Рассмотрим вариационный ряд из промежутков

$$S_{(1)} \leqslant S_{(2)} \leqslant \ldots \leqslant S_{(n)}.$$

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения II

Пусть R — число совпадений $S_{(j)} = S_{(j+1)}$. Можно найти приближение для распределения вероятностей величины R.

Если в году m дней, то нулевые промежутки соответствуют совпадающим дням рождения среди n случайных людей (отсюда название критерия).
В общем случае упорядоченные промежутки будут иметь вид:

$$0 = S_{(1)} = \ldots = S_{(j)} < S_{(j+1)} \leqslant S_{(j+2)} \leqslant \ldots \leqslant S_{(n)}.$$

Здесь из R совпадений $(j-1)$ объясняются нулевыми промежутками. Обозначим через $b_{n,r,j}(m)$ число выборок $(x_1, \ldots, x_n)$, для которых всего будет r совпадений

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения III

промежутков и j нулевых промежутков (как в примере выше).
Тогда, по формуле классической вероятности,

$$\mathbf{P}(R = r) = \frac{1}{m^n} \sum_{j=0}^{r+1} b_{n,r,j}(m)$$

Введем производящие функции

$$b_{n,r}(z) = \sum_{m=0}^{\infty} \frac{b_{n,r,0}(m)}{m} z^m.$$

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения IV

Они имеют сложный вид. Например,

$$b_{n,0}(z) = \frac{n!(n-1)!z^{n(n+1)/2}}{(1-z)\times\ldots\times(1-z^n)},$$

$$b_{n,1}(z) = \frac{1}{2}n!(n-1)!\sum_{k=1}^{n}\frac{(z^k-z^n)z^{n(n-1)/2}}{(1-z)\times\ldots\times(1-z^n)},$$

$$\ldots$$

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения V

Можно получать их последовательно из двойной производящей функции

$$\frac{\sum_{r=0}^{\infty} b_{n,r}(z) w^r}{n!(n-1)!z^n} =$$

$$= \sum_{0 \leqslant b_1, \ldots, b_{n-1} \leqslant 1} \frac{(z - b_1 z^n) \cdots (z^{n-1} - b_{n-1} z^n)}{c_1 \cdots c_{n-1}(1-z) \cdots (1-z^n)} \left(\frac{w}{z^{n-1}}\right)^{b_1} \cdots \left(\frac{w}{z^1}\right)^{b_{n-1}},$$

где $c_k = 1 + b_k + b_k b_{k-1} + \ldots + b_k \cdots b_2 b_1$.
Дальше – больше. Используя спецприемы из анализа (метод перевала), удается в конце концов установить, что при $n \to \infty$, $m = n^3/\alpha$, $\alpha = \text{const}$, вероятность

$$\mathbf{P}(R = r) = \frac{(\alpha/4)^r}{r!} e^{-\alpha/4} + O(n^{-1}).$$

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения VI

Оказывается, критерий Фибоначчи с запаздыванием не удовлетворяет критерию промежутков. Рассмотрим, например, последовательность

$$X_n = (X_{n-24} + X_{n-55}) \mod m.$$

Числа этой последовательности также удовлетворяют соотношению

$$X_n + X_{n-86} \equiv X_{n-24} + X_{n-31} \mod m,$$

откуда

$$X_n - X_{n-24} \equiv X_{n-31} - X_{n-86} \mod m,$$
$$X_n - X_{n-31} \equiv X_{n-24} - X_{n-86} \mod m.$$

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения VII

Всякий раз, когда X_n близко к X_{n-24} или к X_{n-31}, одна и та же разность может появиться в двух промежутках. Получится значительно больше случаев равенств. Например, если выбирать только некоторую подпоследовательность, например, X_0, X_2, X_4, ..., то четверки $\{X_n, X_{n-24}, X_{n-31}, X_{n-86}\}$ будут исключены и проблемы в этом критерии исчезнут.

Listing 8: (Проверяем генератор Фибоначчи с запаздыванием по критерию дней рождения)

```
N <- 512
m <- 2^25
a <- 16807L
x <- integer(N)
R <- integer(50)
for( jj in 1:50){
```

© А.В. Зорин, ННГУ, 2021

Критерий дней рождения VIII

```
    x[1:55] <- sample(m,55)-1;x[1:55]
    for(i in 56:N){
        x[[i]] <- (x[[i-24]]+x[[i-55]]) %% m
    };
    x.s <- sort(x);
    ss <- sort(c(x.s[[1]]+m-x.s[[N]], diff(x.s)))
    R[[jj]] <- length( which(diff(ss)==0) );
}
table(R)
mean(R)
```

© А.В. Зорин, ННГУ, 2021